使用dict和set

4078次阅读

dict

Python内置了字典: dict的支持, dict全称dictionary, 在其他语言中也称为map, 使用键-值 (key-value) 存储, 具有极快的查找速度。

举个例子,假设要根据同学的名字查找对应的成绩,如果用list实现,需要两个list:

```
names = ['Michael', 'Bob', 'Tracy']
scores = [95, 75, 85]
```

给定一个名字,要查找对应的成绩,就先要在names中找到对应的位置,再从scores取出对应的成绩,list越长,耗时越长。

如果用dict实现,只需要一个"名字"-"成绩"的对照表,直接根据名字查找成绩,无论这个表有多大,查找速度都不会变慢。用Python写一个dict如下:

```
>>> d = {'Michael': 95, 'Bob': 75, 'Tracy': 85}
>>> d['Michael']
95
```

为什么dict查找速度这么快?因为dict的实现原理和查字典是一样的。假设字典包含了1万个 汉字,我们要查某一个字,一个办法是把字典从第一页往后翻,直到找到我们想要的字为止, 这种方法就是在list中查找元素的方法,list越大,查找越慢。

第二种方法是先在字典的索引表里(比如部首表)查这个字对应的页码,然后直接翻到该页,找到这个字,无论找哪个字,这种查找速度都非常快,不会随着字典大小的增加而变慢。

dict就是第二种实现方式,给定一个名字,比如'Michael', dict在内部就可以直接计算出 Michael对应的存放成绩的"页码",也就是95这个数字存放的内存地址,直接取出来,所以速度非常快。

你可以猜到,这种key-value存储方式,在放进去的时候,必须根据key算出value的存放位置,这样,取的时候才能根据key直接拿到value。

把数据放入dict的方法,除了初始化时指定外,还可以通过kev放入:

```
>>> d['Adam'] = 67
>>> d['Adam']
```

由于一个key只能对应一个value,所以,多次对一个key放入value,后面的值会把前面的值冲掉:

```
>>> d['Jack'] = 90
>>> d['Jack']
90
>>> d['Jack'] = 88
>>> d['Jack']
```

如果key不存在, dict就会报错:

```
>>> d['Thomas']
```

```
Traceback (most recent call last):
File "<stdin>", line 1, in <module>
KeyError: 'Thomas'
```

要避免key不存在的错误,有两种办法,一是通过in判断key是否存在:

```
>>> 'Thomas' in d
False
```

二是通过dict提供的get方法,如果key不存在,可以返回None,或者自己指定的value:

```
>>> d.get('Thomas')
>>> d.get('Thomas', -1)
-1
```

注意: 返回None的时候Python的交互式命令行不显示结果。

要删除一个key,用pop(key)方法,对应的value也会从dict中删除:

```
>>> d.pop('Bob')
75
>>> d
{'Michael': 95, 'Tracy': 85}
```

请务必注意,dict内部存放的顺序和kev放入的顺序是没有关系的。

和list比较, dict有以下几个特点:

- 1. 查找和插入的速度极快,不会随着key的增加而增加:
- 2. 需要占用大量的内存,内存浪费多。

而list相反:

- 1. 查找和插入的时间随着元素的增加而增加;
- 2. 占用空间小,浪费内存很少。

所以,dict是用空间来换取时间的一种方法。

dict可以用在需要高速查找的很多地方,在Python代码中几乎无处不在,正确使用dict非常重要,需要牢记的第一条就是dict的key必须是不可变对象。

这是因为dict根据key来计算value的存储位置,如果每次计算相同的key得出的结果不同,那 dict内部就完全混乱了。这个通过key计算位置的算法称为哈希算法(Hash)。

要保证hash的正确性,作为key的对象就不能变。在Python中,字符串、整数等都是不可变的,因此,可以放心地作为key。而list是可变的,就不能作为key:

```
>>> key = [1, 2, 3]
>>> d[key] = 'a list'
Traceback (most recent call last):
   File "<stdin>", line 1, in <module>
TypeError: unhashable type: 'list'
```

set

set和dict类似,也是一组key的集合,但不存储value。由于key不能重复,所以,在set中,没有重复的key。

要创建一个set,需要提供一个list作为输入集合:

```
>>> s = set([1, 2, 3])
>>> s
set([1, 2, 3])
```

注意,传入的参数[1, 2, 3]是一个list,而显示的set([1, 2, 3])只是告诉你这个set内部有list0,3这3个元素,显示的[]不表示这是一个list0。

重复元素在set中自动被过滤:

```
>>> s = set([1, 1, 2, 2, 3, 3])
>>> s
set([1, 2, 3])
```

通过add(key)方法可以添加元素到set中,可以重复添加,但不会有效果:

```
>>> s. add (4)
>>> s
set([1, 2, 3, 4])
>>> s. add (4)
>>> s
set([1, 2, 3, 4])
```

通过remove(key)方法可以删除元素:

```
>>> s.remove(4)
>>> s
set([1, 2, 3])
```

set可以看成数学意义上的无序和无重复元素的集合,因此,两个set可以做数学意义上的交集、并集等操作:

```
>>> s1 = set([1, 2, 3])
>>> s2 = set([2, 3, 4])
>>> s1 & s2
set([2, 3])
>>> s1 | s2
set([1, 2, 3, 4])
```

set和dict的唯一区别仅在于没有存储对应的value,但是,set的原理和dict一样,所以,同样不可以放入可变对象,因为无法判断两个可变对象是否相等,也就无法保证set内部"不会有重复元素"。试试把list放入set,看看是否会报错。

再议不可变对象

上面我们讲了,str是不变对象,而list是可变对象。

对于可变对象,比如list,对list进行操作,list内部的内容是会变化的,比如:

```
>>> a = ['c', 'b', 'a']
>>> a.sort()
>>> a
['a', 'b', 'c']
```

而对于不可变对象,比如str,对str进行操作呢:

```
>>> a = 'abc'
>>> a.replace('a', 'A')
'Abc'
```

```
>>> a
'abc'
```

虽然字符串有个replace()方法,也确实变出了'Abc',但变量a最后仍是'abc',应该怎么理解呢?

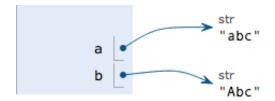
我们先把代码改成下面这样:

```
>>> a = 'abc'
>>> b = a.replace('a', 'A')
>>> b
'Abc'
>>> a
'abc'
```

要始终牢记的是,a是变量,而'abc'才是字符串对象!有些时候,我们经常说,对象a的内容是'abc',但其实是指,a本身是一个变量,它指向的对象的内容才是'abc':



当我们调用a. replace('a', 'A')时,实际上调用方法replace是作用在字符串对象'abc'上的,而这个方法虽然名字叫replace,但却没有改变字符串'abc'的内容。相反,replace方法创建了一个新字符串'Abc'并返回,如果我们用变量b指向该新字符串,就容易理解了,变量a仍指向原有的字符串'abc',但变量b却指向新字符串'Abc'了:



所以,对于不变对象来说,调用对象自身的任意方法,也不会改变该对象自身的内容。相反,这些方法会创建新的对象并返回,这样,就保证了不可变对象本身永远是不可变的。

小结

使用key-value存储结构的dict在Python中非常有用,选择不可变对象作为key很重要,最常用的key是字符串。

tuple虽然是不变对象,但试试把(1, 2, 3)和(1, [2, 3])放入dict或set中,并解释结果。